

toya
Imperative Programmiersprache für die
JVM

Lukas Christian Hofwimmer



MASTERARBEIT

eingereicht am
Fachhochschul-Bachelorstudiengang

Universal Computing

in Hagenberg

im Juli 2021

Betreuung:
FH-Prof. DI Dr. Heinz Dobler

© Copyright 2021 Lukas Christian Hofwimmer

Diese Arbeit wird unter den Bedingungen der Creative Commons Lizenz *Attribution-NonCommercial-NoDerivatives 4.0 International* (CC BY-NC-ND 4.0) veröffentlicht – siehe <https://creativecommons.org/licenses/by-nc-nd/4.0/>.

Erklärung

Ich erkläre eidesstattlich, dass ich die vorliegende Arbeit selbstständig und ohne fremde Hilfe verfasst, andere als die angegebenen Quellen nicht benutzt und die den benutzten Quellen entnommenen Stellen als solche gekennzeichnet habe. Die Arbeit wurde bisher in gleicher oder ähnlicher Form keiner anderen Prüfungsbehörde vorgelegt. Die vorliegende, gedruckte Arbeit ist mit dem elektronisch übermittelten Textdokument identisch.

Hagenberg, am 15. Juli 2021

Lukas Christian Hofwimmer

Inhaltsverzeichnis

| | |
|--------------------------------------|-------------|
| Erklärung | iv |
| Vorwort | vii |
| Kurzfassung | viii |
| Abstract | ix |
| 1 Einleitung | 1 |
| 2 Programmiersprache toya | 2 |
| 2.1 Typen | 2 |
| 2.2 Funktionen | 3 |
| 2.3 Variablen | 4 |
| 2.3.1 Felder | 5 |
| 2.4 Anweisungen | 5 |
| 2.4.1 For-Schleifen | 5 |
| 2.5 Ausdrücke | 5 |
| 2.5.1 Arithmetik | 6 |
| 2.5.2 Boole'sche Logik | 6 |
| 2.5.3 If-Verzweigungen | 6 |
| 2.5.4 Literale | 7 |
| 2.6 Kommentare | 7 |
| 3 Vergleich mit Kotlin | 8 |
| 3.1 Übersicht Kotlin | 8 |
| 3.2 Funktionen | 9 |
| 3.3 Variablen | 9 |
| 3.4 Felder | 10 |
| 3.5 If-Verzweigung | 10 |
| 3.6 For-Schleifen | 10 |
| 4 Generierung des Syntaxbaums | 12 |
| 4.1 ALL(*) Parsing | 13 |
| 4.2 Grammatik-Definition | 13 |
| 4.3 Listener | 13 |

| | | |
|---------------------------|---|-----------|
| 4.4 | Visitor | 14 |
| 5 | JVM und Bytecode | 15 |
| 5.1 | JVM Architektur | 15 |
| 5.2 | Bytecode | 15 |
| 6 | Implementierung | 16 |
| 6.1 | Frontend | 16 |
| 6.1.1 | Grammatik | 17 |
| 6.1.2 | Abarbeitung des Syntaxbaum | 17 |
| 6.1.3 | Typ-System | 18 |
| 6.1.4 | Standardfunktionen | 19 |
| 6.2 | Abstrakter Syntaxbaum (AST) | 20 |
| 6.3 | Backend | 21 |
| 6.3.1 | ObjectWeb ASM | 21 |
| 7 | Tests | 24 |
| 7.1 | Hello World | 24 |
| 7.2 | Funktionen | 25 |
| 7.3 | Variablen | 25 |
| 7.4 | Felder | 27 |
| 7.5 | If-Verzweigungen | 28 |
| 7.6 | For-Schleifen | 29 |
| 7.7 | Umfangreicheres Beispiel | 30 |
| 8 | Zusammenfassung, Schlüsse und Lehren | 32 |
| A | Technische Informationen | 33 |
| B | Ergänzende Inhalte | 34 |
| B.1 | PDF-Dateien | 34 |
| B.2 | Mediendaten | 34 |
| B.3 | Online-Quellen (PDF-Kopien) | 34 |
| C | Fragebogen | 35 |
| D | LaTeX-Quellcode | 36 |
| Quellenverzeichnis | | 37 |
| | Online-Quellen | 37 |

Vorwort

Kurzfassung

Abstract

This should be a 1-page (maximum) summary of your work in English.

Kapitel 1

Einleitung

Kapitel 2

Programmiersprache toya

toya ist eine stark typisierte, turingvollständige Programmiersprache für die *Java Virtual Machine* mit einem Fokus auf Simplizität. Der Syntax ist, wie bei C# oder Java zum Beispiel, stark an C angelehnt. Auf die Syntax wird in diesem Kapitel bei der näheren Behandlung der einzelnen Komponenten der Sprache eingegangen.

Der Name *toya*, in Anlehnung an Java und Kotlin, findet seinen Ursprung bei einer Insel. Dabei handelt es sich konkret um 洞爺湖 (Tōya-ko), einen Kratersee im Norden Japans, der wiederum die Insel 中島 (Nakajima) enthält. Von Tōya-ko leitet sich dann der Name *toya* ab.

Grundsätzlich folgt *toya* dem imperativen Programmierparadigma. Ein *toya*-Programm besteht aus einer Menge an Funktionen und Variablen, wobei wie in Java eine `main`-Funktion zum Programmeinstieg benötigt wird. Klassen gibt es keine. Bei der Übersetzung werden aber alle Programmteile in eine `Main` Klasse zusammengefasst, da das resultierende Kompilat mindestens eine Klasse benötigt. Sollte die `main` Funktion nicht vorhanden sein, so wird eine Ausnahmesituation während der Syntax-Analyse erzeugt. Variablen, die außerhalb von Funktionen definiert werden, stehen global zur Verfügung. Global in diesem Kontext bedeutet, dass solche Variablen in allen Funktionen des Programms verwendet werden können.

Die Benutzer:in hat die Möglichkeit, ein *toya*-Programm auf mehrere Dateien aufzuteilen (zum Beispiel zur besseren Organisation). Anschließend bei der Übersetzung sind alle *toya*-Dateien anzugeben. Unabhängig von der Anzahl an Eingangs-Dateien besteht das kompilierte Programm jedoch immer aus genau einer `class`-Datei.

2.1 Typen

toya stellt insgesamt fünf Typen und Felder von diesen Typen zur Verfügung. Diese sind `boolean`, `int`, `double` und `string`, wobei hierbei `int`, `boolean` und `string` eindeutig die wichtigsten sind, da jeder dieser Typen in unterschiedlichen Domänen seine Verwendung findet. Das Erstellen weiterer Typen ist nicht möglich.

Feld-Typen sind mit dem allgemein bekannten Suffix ‘

’ und dem Schlüsselwort `new` zu deklarieren. So ist zum Beispiel der Typ eines Zeichenketten-

Feld als `string`

zu schreiben. Die JVM bietet zusätzlich noch die Datentypen `byte`, `short`, `long` und `float`, aber weil alle diese Typen redundant in ihrem Aufgabenbereich sind, kommen diese nicht in *toya* vor, da der Sinn von *toya* nicht die vollständige Ausschöpfung aller JVM-Eigenschaften ist, sondern die explorative Implementierung einer Programmiersprache, wofür nicht alle Datentypen benötigt werden. Der `returnAddress`-Typ wird hier außer acht gelassen, weil dieser nur JVM-interne Relevanz hat.

`int` hat einen Wertebereich von -2^{31} bis $2^{31} - 1$; `double` folgt der IEEE-754-Spezifikation: 1 Bit für das Vorzeichen, 11 Bit für den Exponenten und 52 Bit für die Mantisse. `boolean` hat die Werte `true` und `false`. `True` wird intern als 1 mit repräsentiert, `false` mit 0. Die JVM kennt keinen nativen Zeichenketten-Typ, da dieser als Referenz repräsentiert wird. Da *toya* keine Erstellung von Typen erlaubt, sind die einzigen Referenztypen Zeichenketten und Felder. Die Bytecode-Generierung *toyas* unterscheidet immer zwischen Felder und nicht-Felder, wenn es um die Auswahl der richtigen Opcodes geht, dadurch ergibt sich, dass eine Referenz, welche kein Feld ist, immer ein String sein muss. Zeichenketten werden als Literale mit doppelte Anführungszeichen definiert. So ist ein Hello World String als `"Hello World"` anzugeben.

Gewisse Sprachen wie Java oder Kotlin konvertieren automatisch zwischen Typen, wenn diese zum Beispiel in arithmetischen Operationen gemischt werden. So liefert zum Beispiel eine Addition, mit einem Ganzzahl- und Gleitkomma-Operanden eine Gleitkomma-Summe. Dadurch ermöglichen diese Programmiersprachen eine gewisse Flexibilität, selbst bei statischer Typisierung. Diese automatische Konvertierung besitzt *toya* nicht. Stattdessen wird das Programm in einen Ausnahmezustand versetzt, sollten verschiedene Typen in einer Operation vorkommen.

2.2 Funktionen

Funktionen sind die zentrale Komponente von *toya* und enthalten die Programmlogik. Sie bestehen aus Funktionssignatur und Funktionskörper. Die Funktionssignatur besteht aus Funktionsname, Parameter und Rückgabewert. Der Name ist das einzig verpflichtende hierbei; Parameter und Rückgabewert sind optional. Hat eine Funktion keinen Rückgabewert, so fallen sowohl der Pfeil, als auch der nachfolgende Typ weg.

Listing 2.1: Eine typische Funktion unter toya.

```
function add(lhs: int, rhs: int) -> int {
    lhs + rhs
}
```

Der Funktionskörper besteht aus einer beliebige Folge an Anweisungen und Ausdrücken. Hat eine Funktion einen Rückgabewert, so kann mit `return` ein nachfolgender Ausdruck rückgegeben werden. Das Schlüsselwort `return` ist jedoch optional: Wenn die letzte Anweisung gleichzeitig ein Ausdruck und vom geforderten Typen ist, dann wird automatisch dieser Ausdruck geliefert. Hierbei ist jedoch zu beachten, dass die Leserlichkeit erhalten bleibt.

Funktionen werden mit dem Syntax `function <funcname>(parameter*)` aufgerufen und sind vom Rückgabetypen der aufgerufenen Funktion. Für jeden Parameter kann

jeder beliebige Ausdruck eingesetzt werden, solange der Formal- und Aktualtyp übereinstimmt.

2.3 Variablen

toya erlaubt Nutzer:innen die Erstellung von Variablen in Funktionen und auf globaler Ebene. Der Syntax dafür lautet `var <name> = <ausdruck>`; die explizite Angabe eines Typs ist nicht möglich. Stattdessen leitet der Compiler anhand bekannter Typinformation des zu evaluierenden Ausdrucks den Typ ab und weist diesen Typ der Variable zu. Dieser Typ bleibt über die gesamte Lebensdauer der Variable gleich. Sobald der Typ einer Variable fixiert ist, so kann er nicht mehr geändert werden. Initialisiert man also eine Variable mithilfe eines Ganzzahl-Ausdrucks, so ist die Variable bis dessen Speicherplatz durch den Garbage Collector freigegeben wird, vom Typ `int`. Eine getrennte Deklaration und Initialisierung ist nicht möglich.

Abgesehen von typentheoretischer Relevanz bietet die Verwendung des Schlüsselwortes `var` einige Vorteile aber auch Nachteile für Verwender:innen von *toya*. Da `var` alle anderen Typen ersetzt, erleichtert es die Schreibarbeit für Programmierer:innen ungemein. Robert C. Martin sagt jedoch in seinem nominalen Werk *A handbook of agile software craftsmanship* “Code is more read than it is written.”. Daraus folgt, dass die Lesbarkeit wichtiger als *Schreibbarkeit* von Code ist und hierbei zeigen sich dann auch die Schwächen. Mit nur einem Schlüsselwort kann der Typ einer Variablen nicht explizit angegeben werden und muss durch den Leser:in abgeleitet werden, ergo ist die Lesbarkeit von Code, welcher *toya* verwendet, schlechter als bei anderen Sprachen. Um diesem Problem vorzubeugen, bieten moderne IDEs Hinweise auf den Typ in der grafischen Benutzeroberfläche. Aufgrund der geringen Anzahl an Typen in *toya* ist das Fehlen von Typhinweisen jedoch vernachlässigbar. Vergleicht man nun die Variablendeklaration und Initialisierung mit Java, so ist zu erkennen, dass bei der Initialisierung via Literalen die Verwendung von `var` kein Problem darstellt. Will man einer Variable den gelieferten Wert einer Funktion zuweisen, so können hier aber Schwierigkeiten hinsichtlich Schlussfolgerungen auftreten. Daher ist die bewusste und intelligente Vergabe von Variablennamen essenziell.

Listing 2.2: Variablendeklaration in toya

```
var number = 123
var word = "Hello World"
var value = 123.456
var bool = true
var result = someFunction()
```

Listing 2.3: Variablendeklaration in Java (vor Version 10)

```
int number = 123;
String word = "Hello World";
double value = 123.456;
boolean bool = true;
int result = someFunction();
```

Der Name einer Variable darf nur einmal im Gültigkeitsbereich verwendet werden, da es ansonsten zu Unklarheiten kommen kann, welche von mehreren Variablen nun

gemeint ist. Auf die Frage, was sich hinter einem Gültigkeitsbereich verbirgt, wird näher im Kapitel 6 eingegangen. Ein Name darf aus beliebig vielen Groß- und Kleinbuchstaben und Unterstrichen bestehen.

2.3.1 Felder

Felder sind eine eindimensionale Folge eines bestimmten Typs mit einer fixen Länge, welche bei der Deklaration des Feldes angegeben wird und sich über die Lebensdauer des Feldes nicht mehr ändert. Zuweisungen und Deklarationen unterscheiden sich nur leicht von nicht-Feld Variablen. Der Hauptunterschied dabei besteht darin, dass die Länge bei der Deklaration und der Index bei der Zuweisung anzugeben ist.

Felder werden mit der Syntax `var <name> = new <typ>[int-Ausdruck]` deklariert. Mit `<name>[int-Ausdruck] = Ausdruck` wird ein neuer Wert auf die Speicheradresse, dies anhand des Index berechnet wird, geschrieben.

2.4 Anweisungen

Anweisungen sind Befehle, die keinen Wert liefern. Dazu gehören For-Schleifen und Return-Anweisungen.

2.4.1 For-Schleifen

For-Schleifen in *toya* verhalten sich gleich wie in vielen anderen Sprachen, Java zum Beispiel. Sie bestehen aus einem Schleifenkopf und einem Schleifenkörper. Der Schleifenkopf besteht aus drei Teilen von denen alle drei optional sind:

- **Zählvariable:** Eine Variablendeklaration.
- **Abbruchbedingung:** Ein Ausdruck, der zu einem booleschen Wert evaluieren muss. Solange dessen Wert `true` ist, läuft die Schleife.
- **Inkrement-Ausdruck:** Der Ausdruck, welcher nach jedem Schleifendurchlauf evaluiert wird und typischerweise die Zählvariable verändert wird.

Listing 2.4: Eine For-Schleife, die die Zählvariable auf die Konsole ausgibt.

```
for (var i = 0; i <= 10; i++) {  
    println(i)  
}
```

Gibt es keine Abbruchbedingung, so läuft die Schleife, solange das Programm läuft. Wie in Java kann man also mit `for (;;) { ... }` eine Endlos-Schleife erzeugen.

2.5 Ausdrücke

Ausdrücke in *toya* sind alle Konstrukte, welche einen Wert liefern. So sind Funktionsaufrufe, die einen Rückgabewert haben, If-Verzweigungen, boolesche und arithmetische Ausdrücke, Literale und Variablen Ausdrücke. Ausdrücke evaluieren immer zu einem Wert, welcher aus dem Wertebereich eines bestimmten Typs entstammt. Abgesehen vom zwingendem Übereinstimmen des Formal- und Aktualtyps existieren keine Beschränkungen, was das Ersetzen von Ausdrücke durch andere Ausdrücke betrifft.

2.5.1 Arithmetik

toya unterstützt Addition (+), Subtraktion (-), Multiplikation (*) und Division (/) für Ganzzahl- und Gleitkomma-Werte via Infix Notation. Bei der Evaluierung von arithmetischen Ausdrücke wird auf die Klammerung und auf die Operatorrangfolge Rücksicht genommen, sodass arithmetische Ausdrücke in der richtigen Reihenfolge evaluiert werden.

2.5.2 Boole'sche Logik

Boole'sche Ausdrücke sind essenziell für die Verwendung von If-Verzweigungen und For-Schleifen, da sie für die Zweig-Wahl, beziehungsweise als Abbruchbedingung benötigt werden. Zur Auswahl stehen die boole'schen Operatoren 'Und' (&&) und 'Oder' (||) und die relationalen Operatoren Größer (>), Größer-Gleich (>=), Gleich (==), Kleiner-Gleich (<=) und Kleiner (<). Außerdem können boole'sche Ausdrücke mit dem Präfix ! negiert werden. Es ist zu beachten, dass relationale Operatoren eine höhere Rangigkeit als boole'sche Operatoren haben, sodass selbst ohne richtiger Klammerung der Ausdruck auf die erwartete Weise evaluiert wird. Die Rangfolge der Operatoren hierbei entspricht der von C.

2.5.3 If-Verzweigungen

If-Verzweigungen ermöglichen Entwickler:innen, bedingte Ausführung zu implementieren. If-Verzweigungen sind sehr flexibel in ihrer Syntax, da sowohl ein einzelner Ausdruck, als auch ein Block mit mehrere Anweisungen in den Zweigen des Ifs angegeben werden kann.

`if (<boolean-expression>) { <statement>* } else { <statement>* }` ermöglicht die Angabe von mehreren Anweisungen pro Block, wobei jeder Block von geschwungenen Klammern umgeben ist. Hat man die Absicht, nur einen Ausdruck pro Zweig anzugeben, dann reicht `if (<boolean-ausdruck>) expression else expression` völlig aus.

Listing 2.5: If-Verzweigung als klassische Anweisung.

```
var someBoolean = true
if (someBoolean) {
    doSomething()
    print(someBoolean)
} else {
    print(someBoolean)
}
```

Listing 2.6: If-Verzweigung als Ausdruck in einer Variablenzuweisung.

```
var someBoolean = false
var someInteger = if (someBoolean) 4 else 5
```

Die Stärke der If-Verzweigung in *toya* liegt darin, dass es nicht nur ein Anweisung ist, sondern auch die Verwendung als Ausdruck möglich ist. Dadurch kann eine If-Verzweigung auf der rechten Seite einer Variablenzuweisung, in arithmetischen Ausdrücken, als Bedingung in anderen If-Verzweigungen, etc. vorkommen. Andere Programmiersprachen, wie Java, bieten einen ternären Operator `var x = boolean-expression`

? expression : expression. Dieser existiert in *toya* jedoch nicht, da die If-Verzweigung bereits diesen Zweck erfüllt.

Um die Verwendung als Ausdruck zu ermöglichen, ist zu beachten, dass bei If-Verzweigungen mit Blöcken die letzte Anweisung ein Ausdruck sein muss; bei If-Verzweigungen mit Ausdrücken besteht jeder Zweig sowieso nur aus einem Ausdruck, dadurch ist diese Bedingung sowieso gegeben. Außerdem müssen die Typen in allen Zweigen übereinstimmen und der sonst optionale else-Zweig zwingend vorhanden sein. Wäre der else-Zweig nämlich nicht vorhanden, dann wäre unter Umständen kein Wert als Folge der Evaluierung gegeben.

2.5.4 Literale

Literale sind die primitivsten Ausdrücke in *toya* und stellen fixe Werte dar. Jeder Typ hat ein bestimmtes Format für Literale, sodass Typ-Inferenz möglich ist.

- **int:** Alle numerischen Werte ohne Nachkommastellen. (z.B.: 12345)
- **double:** Alle numerischen Werte mit Nachkommastellen. (z.B.: 123.45)
- **string:** Alle Zeichenketten, die von doppelten Anführungszeichen umgeben sind. (z.B.: "Hello World")
- **boolean:** true und false.

2.6 Kommentare

toya erlaubt die Verwendung von Kommentaren. Ein Kommentar beginnt mit einem doppelten Schrägstrich //; alle weiteren Zeichen in dieser Zeile – bis zum Zeilenumbruch – ignoriert der Parser.

Kapitel 3

Vergleich mit Kotlin

Da der *toya*-Compiler in Kotlin implementiert und die Syntax in einigen Aspekten auch an Kotlin angelehnt ist liegt es nahe, einen Vergleich zwischen den beiden Sprachen durchzuführen. Ein besonderer Fokus im Vergleich liegt auf der Syntax, da der generierte Bytecode zwischen den beiden Sprachen kaum zu unterscheiden ist (abgesehen von Optimierungen für individuelle Code-Stücke in Kotlin). Im Folgenden werden nur die wesentlichen Unterschiede zwischen den beiden Sprachen im Umfang von *toya* aufgezeigt. Im Sinne der Prägnanz wird über den direkten Vergleich hinaus nicht näher auf Kotlin eingegangen.

3.1 Übersicht Kotlin

Kotlin ist eine seit 2011 entwickelte statisch typisierte, imperative Programmiersprache mit Elementen der funktionalen Programmierung. Als Antwort von JetBrains auf Java und Scala bietet Kotlin eine plattformübergreifende und idiomatische Programmiersprache, welche nahtlos in das JVM Ökosystem eingegliedert ist. Neben der JVM kompiliert Kotlin auch auf JavaScript, WebAssembly und Assembly. Für letzteres verwendet Kotlin die Compiler-Infrastruktur LLVM. Das momentane Haupt-Anwendungsgebiet liegt in der mobilen Entwicklung unter Android.

Google empfiehlt seit 2019 TODO: Google I/O 2019 reference <https://developer.android.com/kotlin/first> Kotlin anstatt Java zu verwenden und bietet Teile der Standardbibliothek - Jetpack Compose - nur noch unter Kotlin an, da hierbei der Einsatz von Kotlin-spezifischen Compiler Plugins notwendig ist. Andrey Breslav leitete bis 2020 die Entwicklung von Kotlin und übergab anschließend die Verantwortung an Roman Elizarov. Aktuell befindet sich Kotlin bei der Version 1.8.10.

Eines der wichtigsten Merkmale von Kotlin ist die Vermeidung des sogenannten „Billion Dollar Mistake“: Null Pointer. Indem der Compiler bei der unerlaubten Zuweisung von Null-Werten in einen Ausnahmezustand versetzt wird, kann es während der Laufzeit nicht mehr zu unerwünschtem Verhalten kommen. Da es jedoch weiterhin Fälle gibt, in welchen null ein erwünschter Wert ist, kann die Entwickler:in via `?` den Typ einer Variable als *nullable* markieren.

Ein weiteres wichtiges Ziel Kotlins ist die Lesbarkeit des Codes. Dies zeigt sich vor allem in den Methoden der Standardbibliothek. So gibt es zum Überprüfen von Listen auf

deren Leerheit die Methode `isEmpty()`, aber auch dessen Negation mit `isNotEmpty()`. Diese zweite Methode ist redundant, aber erleichtert die Lesbarkeit des Codes ungemein.

Hinsichtlich der funktionalen Programmierung bietet Kotlin eine leicht verwendbare Syntax an, um zum Beispiel die Komposition von Funktionen umzusetzen. Unter anderem stehen Funktionen höherer Ordnung, Lambdafunktionen und Erweiterungsfunktionen zur Verfügung. Diese finden auch häufig Verwendung in der Standardbibliothek: *Scope functions* sind Funktionen höherer Ordnung, die auf ein Objekt eine Lambda-funktion anwenden. Konkret stehen `let`, `run`, `with`, `apply` und `also` zur Verfügung, welche sich in der Art und Weise, wie sie das Objekt behandeln, unterscheiden. Auf diese Funktionen wird nicht näher eingegangen, da diese nicht Teil dieser Bachelorarbeit sind.

3.2 Funktionen

Kotlin verwendet das Schlüsselwort `fun` zur Funktionsdefinition. Der Programmeinstieg geschieht über eine eindeutig identifizierbare `main`-Funktion, welche man optional mit einem `args: String[]` Parameter versehen kann. Entscheidet die Benutzer:in sich dazu, die `main`-Funktion parameterlos zu implementieren, erstellt der Compiler intern eine zweite `main`-Funktion mit `args: String[]` Parameter, welche dazu dient, die, von der Nutzer:in definierte `main`-Funktion aufzurufen.

Listing 3.1: Funktion unter Kotlin

```
fun add(lhs: Int, rhs: Int) : Int {  
    return lhs + rhs  
}
```

Listing 3.2: Funktion unter toya

```
function add(lhs: int, rhs: int) -> int {  
    return lhs + rhs  
}
```

3.3 Variablen

In Kotlin stehen zur Deklaration von Variablen die Schlüsselwörter `var` (Wert ist veränderbar) und `val` (Wert ist unveränderbar) zur Verfügung. Die Bestimmung des Typs erfolgt entweder implizit anhand des zugewiesenen Ausdrucks oder explizit.

`val someString: String = "Hello World"` weist zum Beispiel der Variable *someString* den Wert *Hello World* zu. Die explizite Angabe des Typs *String* ist bei diesem Beispiel redundant, da aus dem Ausdruck der Typ ableitbar ist und daher nicht zwingend notwendig.

Im Gegensatz dazu bietet *toya* zur Variablendeklaration nur das Schlüsselwort `var` an, da in *toya* alle Variablen veränderbar sind. Die explizite Angabe von Typen ist nicht möglich. Der Typ leitet sich immer vom Ausdruck ab.

Listing 3.3: Variablendeklarationen in Kotlin

```
val number: Int = 123
```

```
val word: String = "Hello World"
var value: Double = 123.456
var bool = true
var result = someFunction()
```

Listing 3.4: Variablendeklarationen in *toya*

```
var number = 123
var word = "Hello World"
var value = 123.456
var bool = true
var result = someFunction()
```

3.4 Felder

Kotlin bietet für die Verwendung von Felder die generische Klasse `Array` an. Da Felder, wie in anderen Sprachen, auch in Kotlin statisch in ihrer Größe sind, ist die Anzahl an speicherbaren Elementen als Konstruktorparameter anzugeben. Alternativ dazu besteht die Möglichkeit, mithilfe der Hilfs-Funktion `arrayOf(...)` ein Feld mit Werten zu initialisieren. Für primitive Typen existieren Klassen, *toya* hingegen bezieht sich auf den C-artigen Syntax und verwendet Ausdrücke in der Form von `new <type>[int-expression]` zur Initialisierung von Felder. Die Größe ist ebenso statisch und als Ausdruck innerhalb der eckigen Klammern anzugeben.

Listing 3.5: Felder in Kotlin

```
var arrayViaClass = IntArray(5)
var arrayWithValues = arrayOf(1,2,3,4,5)
arrayViaClass[2] = 5
```

Listing 3.6: Felder in *toya*

```
var array = new int[5]
arra[2] = 5
```

3.5 If-Verzweigung

Die Semantik und Syntax von If-Verzweigungen in *toya* gleichen denen in Kotlin. So kann die Benutzer:in sowohl einen einzelnen Ausdruck als auch einen gesamten Programmblock als Zweig angeben. Ebenso ersetzt die normale If-Verzweigung den ternären Operator, wenn alle Zweige einen Ausdruck darstellen. Dies ist ein weiteres Mittel von Kotlin, die Lesbarkeit des Codes zu verbessern.

Listing 3.7: If-Ausdruck, der sowohl in Kotlin, als auch in *toya* übersetzt

```
var number = if(3 > 4) 5 else 6
```

3.6 For-Schleifen

Während *toya* For-Schleifen im Stil von Java anbietet, hat Kotlin eine deutlich kompaktere, aber auch flexiblere Syntax um über eine Menge zu iterieren. So hat die Benutzer:in

die Möglichkeit entweder über einen `int`-Bereich oder auch über eine Enumeration zu iterieren. Ein wesentlicher Unterschied zu Java hinsichtlich For-Schleifen ist die Abwesenheit des Inkrement Operators in *toya*. Stattdessen muss die Inkrementierung mithilfe des Zuweisungs- und Additions-Operator erfolgen, zum Beispiel: `i = i+1`.

Listing 3.8: Einfache For-Schleife in Kotlin

```
for (i in 0..10 step 2) {  
    println(i)  
}
```

Listing 3.9: Einfache For-Schleife in toya

```
for (var i = 0; i <= 10; i = i+2) {  
    print(i)  
}
```

Kapitel 4

Generierung des Syntaxbaums

ANTLR (**A**Nother **T**ool for **L**anguage **R**ecognition) ist ein seit 1989 entwickeltes Werkzeug von Terrence Parr zum Erzeugen von Parsern, Lexern und Compilern. Die Benutzer:in definiert diese mit einer Grammatik und erzeugt daraus dann mithilfe eines von ANTLR zur Verfügung gestelltem Kommandozeilen-Werkzeug Parser und Lexer in der gewünschten Ziel-Sprache. ANTLR unterstützt unter anderem Java, C#, Python, JavaScript, Go, C++, Swift, PHP und Dart. *toya* bietet als aktuellste Version 4 an, welche jedoch große Unterschiede - allen voran der Umstieg auf eine effizientere Parsing-Methodik - zu Version 3 bietet.

ANTLR findet auch im professionellen Umfeld Verwendung. So verwendet Twitter ANTLR zur Syntax-Analyse von über 2 Milliarden Suchanfragen pro Tag. Hadoop verwendet ANTLR zur Syntax-Analyse von *Hive* und *Pig* und Netbeans analysiert den Syntax von *C++* mithilfe ANTLR.

Der große Vorteil von ANTLR gegenüber selbst entwickelten Lösungen zum Erzeugen von Syntaxbäumen ist die Effizienz mit welcher neue Grammatikregeln definiert werden können. Diese Effizienz und Leichtigkeit in der Umsetzung hat jedoch auch seine Kosten. Da ANTLR einen umfangreichen Syntaxbaum erzeugt und es sehr unwahrscheinlich ist, dass das Programm alle Daten des Syntaxbaums benötigt, kommt es zu einem Mehraufwand für Daten, die keinen Nutzen finden.

Deswegen verwenden alle größeren Programmiersprachen (C++, Python, C#, Java, etc.) selbst entwickelte Lexer und Parser um eine substantielle Reduktion der Übersetzungszeiten zu erreichen.

Da *toya* über eine experimentelle Programmiersprache nicht hinaus geht und es den programmatischen Aufwand sprengt, wurde aktiv gegen eine maßgeschneiderte Lösung für *toya* entschieden. Die Übersetzungszeiten unter Verwendung von ANTLR sind im Rahmen von *toya* akzeptabel. Lexer und Parser, die durch ANTLR erzeugt werden sind nicht schnell, aber schnell genug.

Nun stellt sich die Frage: Wieso nicht auf reguläre Ausdrücke zurückgreifen? Dafür existieren mehrere Gründe:

- Kein rekursives Parsing möglich.
- Programmelemente, die an allen Stellen im Code - Kommentare zum Beispiel - auftauchen können, sind an allen potenziellen Stellen im Regex-Ausdruck zu berücksichtigen. Dies führt zu Redundanz.

- Reguläre Ausdrücke wachsen schnell und sind schwer zu verwalten. Da Programmiersprache typischerweise auch in ihrem Funktionsumfang wachsen, sind reguläre Ausdrücke nicht dafür geeignet und führen zu einer schlechten Skalierbarkeit.

4.1 ALL(*) Parsing

Adaptive LL(*) Parsing stellt den größten Unterschied zwischen ANTLR3 und ANTLR4 dar.

4.2 Grammatik-Definition

Die Grammatik-Definition in einer `g4`-Datei ist der Ausgangspunkt für alle weiteren Schritte in ANTLR. Diese Datei beinhaltet alle Regeln für den Lexer und Parser und Meta Informationen anhand welcher Eingabe-Dateien abgearbeitet sind. Meta Informationen befinden sich typischerweise am Beginn der Datei.

Da Leerzeichen in der Regel unwichtig sind und keine Relevanz für die Semantik der Sprachen haben (abgesehen von Ausnahmefällen wie Python), ignoriert man diese. Dies erfolgt mithilfe der Anweisung `[\t\n\r]+ -> skip`, welche angibt, dass Leerzeichen bei der Abarbeitung einer Eingabedatei zu überspringen sind.

Ob eine Regel den Parser oder Lexer betrifft, hängt vom Anfangsbuchstaben dieser Regel ab. Ist das erste Zeichen ein Großbuchstabe, betrifft es den Lexer; wenn nicht, den Parser. Typischerweise werden als Erstes Regeln für den Parser und als Zweites Regeln für den Lexer definiert. Die Reihenfolge der Lexer-Regeln ist von Relevanz, da in derselben Reihenfolge ANTLR diese Regeln analysiert.

Listing 4.1: Beispielhafter Aufbau einer Grammatik-Definition für Additionen

```
grammar: addition;

// Parser Regeln
operation : NUMBER '+' NUMBER ;

// Lexer Regeln
NUMBER   : [0-9]+ ;
WHITESPACE : [ \t\n\r]+ -> skip ;
```

4.3 Listener

Um die Ergebnisse des Syntaxbaums abarbeiten zu können, bietet ANTLR zwei Entwurfsmuster an: *Visitor* und *Listener*. Diese erzeugt die Benutzer:in mithilfe des Kommandozeilen-Werkzeug `antlr4`. Die Implementierung für diese Entwurfsmuster erzeugt das Werkzeug dann in einem benutzerdefinierten Ordner anhand der angegebenen Grammatik-Datei. Außerdem gibt die Benutzer:in zusätzlich noch an, ob entweder die Implementierung für *Visitor* oder *Listener* oder für Beide zu generieren sind. Sollen keine *Listener* generiert werden, ist dies via dem Argument `-no-listener` anzugeben.

Listener haben im Gegensatz zum *Visitor* keinen Einfluss auf den Analyse-Vorgang. Stattdessen ruft der *Tree Walker*, der den Syntaxbaum traversiert, die von ANTLR

generierten Methoden für den richtigen Knotentyp anhand der Analyse-Regeln auf. Diese Methoden des *Listeners* liefern keinen Wert zurück, was die Verwaltung eines abstrakten Syntaxbaums erschwert. Aufgrund der Komplexität von *toya* sind *Listener* daher nicht empfehlenswert.

Listener bieten sich gut für Zusatzverhalten an, welches den Syntaxbaum nicht verändert. Typische Verwendungszwecke für *Listener* ist das Loggen von Informationen oder ermitteln von Metadaten.

4.4 Visitor

Das *Visitor* Pattern ist ein Entwurfsmuster, das es ermöglicht, eine Operation auf den Elementen einer Objektstruktur auszuführen, ohne die Klassen dieser Elemente zu ändern oder die Struktur selbst zu verändern.

Das Entwurfsmuster besteht aus zwei grundlegenden Komponenten: den Elementen der Objektstruktur und dem Visitor, der die Operation auf den Elementen ausführt. Die Elemente der Struktur implementieren eine gemeinsame Schnittstelle, das den *Visitor* akzeptiert. Der *Visitor* selbst definiert Methoden für jede Klasse von Elementen, die er besuchen kann.

Um das Entwurfsmuster zu nutzen, ruft man die **accept**-Methode des *Visitors* auf dem Wurzelement der Struktur auf, welches die Schnittstelle für die Elemente implementiert. Diese Methode wiederum ruft die entsprechende Methode im *Visitor* auf, wodurch dieser das Element besucht. Das Element gibt sich selbst als Parameter an den *Visitor* weiter, wodurch dieser auf die Eigenschaften und Methoden des Elements zugreifen und eine Operation darauf ausführen kann. Ein mögliches Problem hierbei ist, dass Fehler leichter entstehen können. Vergisst die Entwickler:in auf den Aufruf einer notwendigen **accept**-Methode, kommt es nicht zur Versetzung des Programms in einen Ausnahmezustand, sondern die zu parsenden Token werden ignoriert.

Das *Visitor* Entwurfsmuster hat den Vorteil, dass es das Open-Closed-Prinzip unterstützt, da neue Operationen durch die Erstellung neuer *Visitor*-Klassen hinzugefügt werden können, ohne die existierenden Elementklassen zu ändern. Außerdem können komplexe Operationen auf der Objektstruktur durchgeführt werden, indem man mehrere *Visitor*-Klassen erstellt, die jeweils eine Teiloperation durchführen.

```
1 class ExpressionVisitor(val scope: Scope) : toyaBaseVisitor<Expression>() {
2     override fun visitValue(valueContext: toyaParser.ValueContext): Expression {
3         val value = valueContext.text
4         val type = TypeResolver.getFromValue(value)
5         return Value(value, type)
6     }
7     // Rest of class...
8 }
```

Kapitel 5

JVM und Bytecode

die Java Virtual Machine (JVM) ist eine von James Gosling für Sun konzipierte und in Folge von Oracle weiterentwickelte Stack-basierte virtuelle Maschine, die die Ausführung von Bytecode unter Linux, MacOS und Windows ermöglicht. Zu Beginn für die plattformunabhängige Ausführung von Java-Code entwickelt, existiert eine Vielzahl an Programmiersprachen für die JVM. Dazu gehören unter anderem neben Java Kotlin/JVM, Scala, Clojure.

5.1 JVM Architektur

5.2 Bytecode

Der Bytecode


Kapitel 6

Implementierung

Die Implementierung des Compilers ist in zwei Teile aufgeteilt: Frontend und Backend. Die Kommunikation zwischen den beiden Teilen erfolgt mithilfe eines abstrakten Syntaxbaums (AST), welchen das Frontend erzeugt. Dieses Kapitel geht auf die Architektur und Implementierung dieser Teile ein.

Die Implementierung erfolgt in Kotlin, was das Einbinden von bereits existierende Bibliotheken des JVM Ökosystems problemlos ermöglicht. Konkret geht es dabei um ANTLR und ObjectWeb ASM, welche wichtige Rollen im Compiler übernehmen. Die Möglichkeit, Summentypen in Form von *sealed* Schnittstellen und Klassen implementieren zu können, erleichtert die Abarbeitung des ASTs wesentlich.

Abbildung 6.1: Compiler-Architektur



6.1 Frontend

Im Frontend erfolgt die lexikalische, syntaktische und teilweise die semantische Analyse. Die lexikalische Analyse zerlegt anhand der bereitgestellten Grammatik den Quellcode in *Token*. Anhand dieser *Token* erstellt die syntaktische Analyse den Syntaxbaum, welcher als Basis für den abstrakten Syntaxbaum dient.

6.1.1 Grammatik

Als Ausgangspunkt des Frontends dient die Grammatik, anhand welcher ANTLR die lexikalische und syntaktische Analyse implementiert. Diese Grammatik definiert die Compiler-Bauer:in in einer `g4`-Datei. Leerzeichen haben keine semantische Relevanz, weshalb *toya* diese in der syntaktischen Analyse überspringt. Als *Token* definiert *toya* folgende Zeichen:

- Die Schlüsselwörter `match`, `for`, `if`, `else`, `var`, `true`, `false` und `null`
- Die Infix-Operatoren `>`, `>=`, `<`, `<=`, `==`, `!=`, `&&`, `||` und der Präfix-Operator `!`
- Die arithmetischen Operatoren `+`, `-`, `*` und `/`

Beim Versuch, ein Schlüsselwort als Variablenname zu Verwenden tritt ein Ausnahmezustand `VariableNameIsKeywordException` ein.

Listing 6.1: Befehl zur Erzeugung der Visitor-Klassen für *toya*

```
antlr4 -o C:\home\Lukas\projects\toya\src\main\java\gen \
  -package gen \
  -Dlanguage=Java \
  -visitor \
  -no-listener \
  -lib C:/home/Lukas/projects/toya/src/main/resources \
  C:/home/Lukas/projects/toya/src/main/resources/toya.g4
```

6.1.2 Abarbeitung des Syntaxbaum

Wie bereits im Kapitel Generierung des Syntaxbaum⁴ erläutert, bietet ANTLR die Entwurfsmuster *Visitor* und *Listener* an, um den Syntaxbaum zu traversieren. *Toya* verwendet das *Visitor*-Muster aufgrund des Umfangs des zu traversierenden Syntaxbaums. Das Resultat des *Visitors* ist ein AST mit dem Wurzelement `Compilation`. Diese Klasse speichert die Funktionssignaturen, globale Variablen und ein globales `Scope`, welches sich über das ganze Programm erstreckt. Alle weiteren `Scopes` nehmen dieses globale `Scope` als Grundlage.

Die wichtigste Methode des *Visitor*, welche die Abarbeitung des Syntaxbaums überhaupt ermöglicht ist die `accept()` Methode. Diese Methode benötigt als Parameter einen *Visitor* vom generischen Typ `ParseTreeVisitor`. *Toya* implementiert folgende *Visitor*:

- `CompilationVisitor`
- `StatementVisitor`
- `BranchVisitor`
- `CompositeVisitor`
- `ExpressionVisitor`
- `FunctionSignatureVisitor`
- `FunctionVisitor`

Zum traversieren des Syntaxbaums generiert ANTLR für jede Regel in der Grammatik-Definition eine Methode im Format `visit<RuleName>(ctx: toyaParser.<RuleName>Context)`. Jede dieser Methoden liefert einen Wert zurück, der dem generischen Typ des `toyaBaseVisitor` entspricht.

Listing 6.2: *Visitor*-Funktion zum Erstellen eines `VariableDeclarationStatement`

```

class StatementVisitor(val scope: Scope) : toyaBaseVisitor<Statement>() {
    override fun visitVariableDeclaration(ctx: toyaParser.VariableDeclarationContext
    ): Statement {
        val varName = ctx.name().text
        if(varName.isReservedKeyword()) throw VariableNameIsKeywordException(varName)
    }
    val expression = ctx.expression().accept(ExpressionVisitor(scope))
    scope.addLocalVariable(LocalVariable(varName, expression.type))
    return VariableDeclarationStatement(varName, expression)
}
// Rest of class
}

```

Befinden sich Syntaxfehler im Quelltext, bietet ANTLR die Basisklasse `BaseErrorListener` um der Benutzer:in relevante Informationen anzuzeigen. *Toya* zeigt mithilfe dieser Klasse an, welche Anweisung in welcher Zeile und welches Zeichen syntaktische Analyse verhindert.

Listing 6.3: Erstellen des *Visitor*

```

class Parser {
    fun getCompilation(files: List<File>): Compilation {
        return files.use {path ->
            val charStream = CharStreams.fromPath(path)
            val lexer = toyaLexer(charStream)
            val tokenStream = CommonTokenStream(lexer)
            val parser = toyaParser(tokenStream)

            val errorListener = ToyaTreeWalkErrorListener()
            parser.addErrorListener(errorListener)

            val compilationVisitor = CompilationVisitor()
            parser.compilation().accept(compilationVisitor)
        }
    }
}

```

6.1.3 Typ-System

Die Basis für das Typ-System in *toya* ist die **Type**-Schnittstelle und die davon abgeleitete Enum-Klasse `BasicType`, welche alle in *toya* verfügbaren Typen zur Verfügung stellt. *Toya* erlaubt keine explizite Definition des Typs einer Variable, weshalb der Typ immer vom Wert der Variable abzuleiten ist. Hierbei kommt der `TypeResolver` zum Einsatz. Anhand von regulären Ausdrücken ermittelt dieser den Typ des Wert-Literals.

Listing 6.4: Methode zur Ermittlung des Typs bei Wert-Literalen

```

fun getFromValue(value: String?): Type {
    if (value.isNullOrEmpty()) return BasicType.VOID
    if (isBoolean(value)) return BasicType.BOOLEAN
    if (isDouble(value)) return BasicType.DOUBLE
    if (isInt(value)) return BasicType.INT
    if (isString(value)) return BasicType.STRING
    throw UnableToInferTypeException(value)
}

```

`TypeResolver` bietet außerdem Hilfsmethoden zur individuellen Behandlung von Typen. Diese Methoden kommen zum Einsatz bei der Generierung der Bytecode Anweisungen, da jeder Typ unterschiedliche Anweisungen verlangt. So ist zum Laden von Zeichenketten zum Beispiel `ALOAD` nötig, wohingegen für Ganzzahlen `ILOAD` zu verwenden ist.

Listing 6.5: Hilfsmethode zur Behandlung der Nicht-Feld Typen

```
fun <T> Type.handleTypeGroups(
    i: () -> T,
    d: () -> T,
    a: () -> T,
    z: () -> T
): T {
    return when (this) {
        BasicType.INT -> i()
        BasicType.DOUBLE -> d()
        BasicType.STRING -> a()
        BasicType.BOOLEAN -> z()
        else -> throw NotImplementedError("handling for type '${this.typeName}' not implemented")
    }
}
```

Da nun die jeder Ausdruck Typinformationen besitzt, ermöglicht das die semantische Analyse von Ausdrücken. Die Funktion `checkTypeMatch()` überprüft, ob beide Operanden vom selben Typ sind. Wenn nicht, wechselt das Programm in einen Ausnahmezustand.

Listing 6.6: Methode zur Überprüfung, dass Operanden übereinstimmende Typen haben

```
fun Type.checkTypeMatch(rhs: Type) {
    if (this != rhs) throw BinaryOperationTypeMismatchException(this, rhs)
}
```

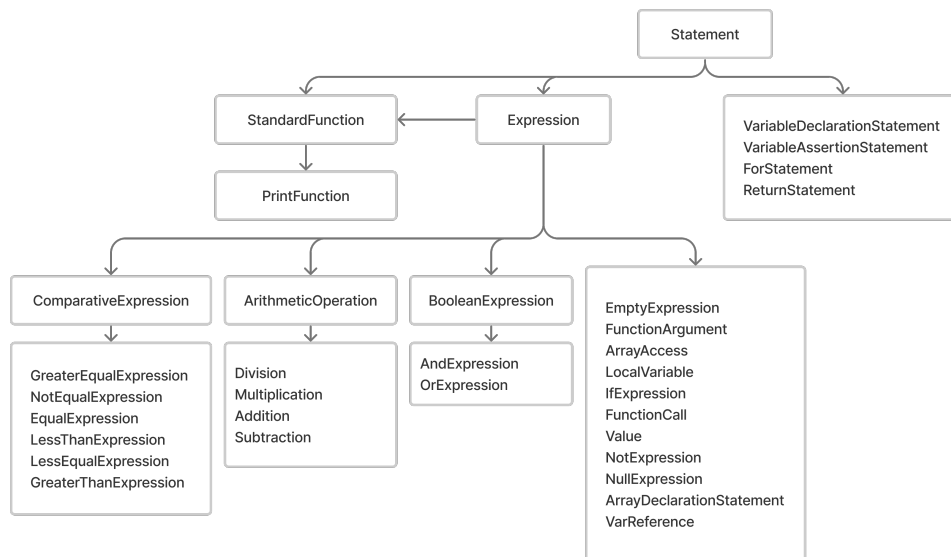
6.1.4 Standardfunktionen

Toya bietet keine Standardbibliothek, jedoch aber die Möglichkeit Standardfunktionen zu implementieren. Standardfunktionen sind kein Bestandteil der lexikalischen Analyse. Stattdessen überprüft die Funktion `visitFunctionCall` des `ExpressionVisitors` mithilfe der Funktion `isStandardFunction()`, ob es sich um eine Standardfunktion handelt. Ist dies der Fall, erzeugt der *Visitor* kein Objekt vom Typ `FunctionCall`, sondern ein Objekt, welches von `StandardFunction` erbt. Im Fall von `print()` ist das zum Beispiel `PrintFunction`.

Standardmäßig bietet *toya* die Standardfunktion `print()` an, welche einen Aufruf der Java Funktion `System.out.println()` durchführt. Die Architektur des *toya*-Compilers ist darauf ausgelegt, weitere Standardfunktionen hinzufügen zu können. Besteht dieser Wunsch, sind an folgenden Stellen von Entwicklerseite her Veränderungen vorzunehmen:

- Im `when` innerhalb der `ExpressionVisitor.visitFunctionCall()` Funktion muss ein Fall für die zu implementierenden Funktion hinzugefügt werden.

Abbildung 6.2: AST-Architektur für Ausdrücke und Anweisungen



- Innerhalb der `StandardFunctions.kt` Datei: In der `standardFunctions` Liste ist eine FunktionsSignatur der neuen Standardfunktion hinzuzufügen und eine Klasse, welche von `StandardFunction` und `Expression` erbt, zu definieren.
- In der `StandardFunctionGenerator` Klasse ist der zu generierende Bytecode zu definieren.

6.2 Abstrakter Syntaxbaum (AST)

Die explizite Umwandlung auf einen abstrakten Syntaxbaum ist theoretisch nicht immer nötig. *toya* verwendet aber ANTLR und der daraus resultierende Syntaxbaum enthält teilweise zu viele Informationen. Teilweise fehlen auch notwendige Informationen, wie zum Beispiel die über den Typ eines Ausdrucks. Daher macht es Sinn, diesen Syntaxbaum auf einen abstrakten Syntaxbaum (AST) umzubauen. Der Großteil des AST behandelt die Einteilung von Ausdrücken und Anweisungen in ein granulareres Klassenschema. Die Einteilung in zum Beispiel `LessEqualExpression` und `ForStatement` anstatt die bloße Gliederung in `Expression` und `Statement` ermöglicht eine gut skalierbare und verständliche Lösung für die Bytecode-Generierung.

Kotlin bietet zur kompakten Erstellung von Datenobjekten sogenannte *data classes* an. `data class` Objekte erzeugen für Mitglieder des primären Konstruktors folgende Funktionen:

- `equals()` und `hashCode()`.

- `toString()` im Format `Addition(left=42, right=31)`.
- `componentN()`, die bei der Destrukturierung von Objekten verwendet werden. Hierbei ist die angegebene Reihenfolge relevant.
- `copy()` zum durchführen einer tiefen Kopie des Objekte.

Toya verwendet *data classes* für fast alle Klassen des AST. Ausgenommen sind Basis Klassen, von denen andere Klassen ableiten, da die Vererbung von *data classes* zu Problemen mit dem Verhalten von *equals()* zum Beispiel führt. Java bietet seit Version 14 `record` als Äquivalent zu diesem Konzept an. Jedoch fehlen bei `record` die `componentN()` und `copy()` Funktionen.

Die `Scope` Klasse ist eine zentrale Komponente in der Verwaltung des AST und wird unter anderem für die semantische Analyse benötigt. Sie speichert die lokalen Variablen für einen gegebenen Block und die Methodensignaturen eines *toya* Programms. Bei Operationen, deren Operanden lokale Variablen sind, überprüft *toya* mithilfe `Scope`, ob diese Variablen im momentanten Kontext zur Verfügung stehen.

Im Zuge der Bytecode-Generierung ermittelt *toya* mithilfe `Scope` den Index einer lokalen Variable. Hierbei reicht es nicht aus, den Index der Variable in der Liste `localVariables` zu ermitteln. Variablen vom Typ `Double` und `Long` benötigen zwei Plätze im *Run-Time Constant Pool*, da deren Indizes 16 Bit, anstatt der üblichen acht Bit einnehmen. Da *toya* den Typ `Double` implementiert, ist diese Eigenschaft zu berücksichtigen. Diese Berechnung erfolgt durch eine Reduktions-Operation in der Funktion `getLocalVariableIndex`. Diese Reduktions-Operation summiert alle Indizes bis inklusive dem Index der gesuchten Variable auf und addiert pro Index eins, beziehungsweise zwei, wenn die Variable vom Typ `Double` ist, mit dem Akkumulator auf.

Listing 6.7: Ermittlung des Index einer Variable in einem `Scope`

```
fun getLocalVariableIndex(varName: String) : Int {
    // hotfix for handling 2-wide index types (double, long, etc)
    return localVariables
        .subList(0, localVariables.indexOf(getLocalVariable(varName)))
        .fold(0) { acc, next ->
            acc + if (next.type == BasicType.DOUBLE) 2 else 1
        }
}
```

`Scope` verwaltet nicht nur Variablen, sondern auch Funktionssignaturen. Beim Aufruf einer Funktion, überprüft `Scope`, ob diese Funktion auch definiert ist. Wenn nicht, tritt der Ausnahmezustand `MethodSignatureNotFoundException` ein. Während das Überladen von Funktionen erlaubt ist, können keine Funktionen mit identischer Signatur existieren, da diese in einem `Set` gespeichert sind.

6.3 Backend

6.3.1 ObjectWeb ASM

ObjectWeb ASM ist eine Bibliothek zum Lesen, Bearbeiten und Erzeugen von Bytecode für die JVM. Sie bietet eine Schnittstelle, um Funktionen, Klassen und einzelne Anweisungen zu erzeugen. *toya* verwendet ASM zum Erzeugen einer Klasse und Funktionen anhand des AST. Neben der Bytecode-Generierung erfolgt im Backend der Teil

der semantischen Analyse für welchen Informationen des AST notwendig sind.

Da *toya* keine Definition von Klassen erlaubt, reicht es aus, eine statische Klasse, unabhängig von Quelltext zu generieren. Version dieser Klasse ist 52, was Java 8 entspricht. Eine höhere Version ist nicht nötig, da alle Bestandteile von *toya* sehr primitiv sind.

Klassen erstellt ASM mithilfe des `ClassWriter`. Der Konstruktor dieser Klasse hat einen Parameter `flags`. Im Falle von *toya* ist dies `COMPUTE_FRAMES + COMPUTE_MAXS`. `COMPUTE_MAXS` und `COMPUTE_FRAMES` ermöglicht die automatische Berechnung der maximal erlaubten Anzahl an lokalen Variablen, die maximale Größe des Stacks und die Berechnung aller *Stack Map Frames*.

Listing 6.8: ASM Code zum Erstellen der Klasse, welche ein *toya* Programm definiert.

```
val classWriter: ClassWriter = ClassWriter(
    ClassWriter.COMPUTE_FRAMES + ClassWriter.COMPUTE_MAXS
)
classWriter.visit(
    CLASS_VERSION,
    Opcodes.ACC_PUBLIC,
    className,
    null,
    "java/lang/Object",
    null
)
```

Im Backend kommen Summen Typen in Form von *sealed classes* zum Einsatz. *sealed classes* in Kotlin besitzen die besondere Eigenschaft, dass alle Kindklassen zur Übersetzungszeit vollständig bekannt sind. Dies ermöglicht zum Beispiel die Verwendung von erschöpfenden `when`-Ausdrücken in Kombination mit Polymorphismus. Kindklassen einer *sealed class* sind alle im selben Modul zu definieren. Neben Klassen können auch Schnittstellen als *sealed* markiert werden.

Listing 6.9: Die `generate()` Funktion von `StatementGenerator`, welche *sealed classes* nutzt.

```
fun generate(statement: Statement, scope: Scope) {
    when (statement) {
        is VariableDeclarationStatement -> generate(statement, scope)
        is ArrayDeclarationStatement -> generate(statement, scope)
        is VariableAssertionStatement -> generate(statement, scope)
        is Expression -> expressionGenerator.generate(statement, scope)
        is ReturnStatement -> generate(statement, scope)
        is ForStatement -> generate(statement)
    }
}
```

Die JVM ist eine Stack-basierte virtuelle Maschine. Das bedeutet, dass ein Operanden-Stack existiert, auf welchen alle Werte, die die Bytecode Anweisungen benötigen, liegen.

Listing 6.10: `generate()` Funktion, welche Wert-Literale erzeugt.

```
private fun generate(value: Value) {
    val type = value.type
    val stringValue = value.value

    type.handleTypeGroups(
```

```
        i = {
            val intValue = stringValue.toInt()
            methodVisitor.visitLdcInsn(intValue)
        },
        d = {
            val doubleValue = stringValue.toDouble()
            methodVisitor.visitLdcInsn(doubleValue)
        },
        a = { methodVisitor.visitLdcInsn(stringValue.trim('"')) },
        z = {
            val opcode = if (stringValue == "true") Opcodes.ICONST_1 else Opcodes.
ICONST_0
            methodVisitor.visitInsn(opcode)
        }
    )
}
```


Kapitel 7

Tests

Um die Funktionalität von *toya* zu gewährleisten, sind Tests zu vollziehen. Diese Tests verlaufen in drei Schritte, wie folgt:

1. Programmcode in *toya* schreiben
2. den kompilierten Bytecode analysieren
3. Die Ausgabe des Programms überprüfen

Die Analyse des Bytecode erfolgt mit dem, in der JDK inkludierten Werkzeug `javap`. Dieses erlaubt es, den Bytecode einer `class`-Datei in einer für Menschen leserlicher Form auszugeben. Der Aufruf erfolgt über die Kommandozeile im Format: `javap -c Main.class`. Das Argument `-c` zeigt zusätzlich die Bytecode Befehle innerhalb der Methoden an. Die Ausführung der Programme erfolgt über die Kommandozeile mit dem Befehl `java Main`.

Insgesamt gilt es, die einzelnen Sprachkonstrukte, wie zum Beispiel For-Schleifen und Variablendeklaration und anschließend umfangreichere Programme zu testen.

7.1 Hello World

Listing 7.1: Quelltext des Hello World Programms

```
function main(args: string[]) {  
    print("Hello World")  
}
```

Listing 7.2: Bytecode des Hello World Programms

```
public class Main {  
    public static void main(java.lang.String[]);  
        Code:  
        0: getstatic      #12      // Field java/lang/System.out:Ljava/io/PrintStream;  
        3: ldc            #14      // String Hello World  
        5: invokevirtual #20      // Method java/io/PrintStream.println:(Ljava/lang/  
String;)V  
        8: return  
}
```

Listing 7.3: Konsolen-Ausgabe des Hello World Programms

```
Hello World
```

7.2 Funktionen

Listing 7.4: Funktionen

```
function title() {
  print("This is an addition:")
}

function add(lhs: int, rhs: int) -> int {
  lhs + rhs
}

function main(args: string[]) {
  title()
  print(add(1,2))
}
```

Listing 7.5: Bytecode für Funktionen

```
public class Main {
  public static void title();
    Code:
      0: getstatic    #12    // Field java/lang/System.out:Ljava/io/PrintStream;
      3: ldc          #14    // String This is an addition:
      5: invokevirtual #20    // Method java/io/PrintStream.println:(Ljava/lang/
String;)V
      8: return

  public static int add(int, int);
    Code:
      0: iload_0
      1: iload_1
      2: iadd
      3: ireturn

  public static void main(java.lang.String[]);
    Code:
      0: invokestatic  #26    // Method title:()V
      3: getstatic    #12    // Field java/lang/System.out:Ljava/io/PrintStream;
      6: ldc          #27    // int 1
      8: ldc          #28    // int 2
     10: invokestatic  #30    // Method add:(II)I
     13: invokevirtual #33    // Method java/io/PrintStream.println:(I)V
     16: return
}
```

Listing 7.6: Konsolen-Ausgabe der Funktionen

```
This is an addition:
3
```

7.3 Variablen

Listing 7.7: Variablen

```

function someFunction() -> int {
    return 8
}

function main(args: string[]) {
    var number = 123
    var word = "Hello World"
    var double = 123.456
    var bool = true
    var result = someFunction()

    print(number)
    print(word)
    print(double)
    print(bool)
    print(result)
}

```

Listing 7.8: Bytecode von Variablen

```

public class Main {
    public static int someFunction();
    Code:
        0: ldc          #7              // int 8
        2: ireturn

    public static void main(java.lang.String[]);
    Code:
        0: ldc          #10             // int 123
        2: istore_1
        3: ldc          #12             // String Hello World
        5: astore_2
        6: ldc2_w       #13             // double 123.456d
        9: dstore_3
       10: iconst_1
       11: istore        5
       13: invokestatic #16             // Method someFunction:()I
       16: istore        6
       18: getstatic    #22             // Field java/lang/System.out:Ljava/io/PrintStream;
       21: iload_1
       22: invokevirtual #28             // Method java/io/PrintStream.println:(I)V
       25: getstatic    #22             // Field java/lang/System.out:Ljava/io/PrintStream;
       28: aload_2
       29: invokevirtual #31             // Method java/io/PrintStream.println:(Ljava/lang/
String;)V
       32: getstatic    #22             // Field java/lang/System.out:Ljava/io/PrintStream;
       35: dload_3
       36: invokevirtual #34             // Method java/io/PrintStream.println:(D)V
       39: getstatic    #22             // Field java/lang/System.out:Ljava/io/PrintStream;
       42: iload        5
       44: invokevirtual #37             // Method java/io/PrintStream.println:(Z)V
       47: getstatic    #22             // Field java/lang/System.out:Ljava/io/PrintStream;
       50: iload        6
       52: invokevirtual #28             // Method java/io/PrintStream.println:(I)V
       55: return
}

```

Listing 7.9: Konsolen-Ausgabe der Variablen

```
123
Hello World
123.456
true
8
```

7.4 Felder

Listing 7.10: Felder

```
function main(args: string[]) {
    var arr = new int[8]
    arr[3] = 15

    print(arr[3])
    print(arr[4])
}
```

Listing 7.11: Bytecode von Felder

```
public class Main {
    public static void main(java.lang.String[]);
    Code:
        0: ldc         #7      // int 3
        2: ldc         #8      // int 4
        4: if_icmpgt   11
        7: iconst_0
        8: goto        12
       11: iconst_1
       12: ifne        20
       15: ldc         #9      // int 6
       17: goto        22
       20: ldc         #10     // int 5
       22: istore_1
       23: getstatic   #16     // Field java/lang/System.out:Ljava/io/PrintStream;
       26: iload_1
       27: invokevirtual #22     // Method java/io/PrintStream.println:(I)V
       30: ldc         #7      // int 3
       32: ldc         #8      // int 4
       34: if_icmplt   41
       37: iconst_0
       38: goto        42
       41: iconst_1
       42: ifne        56
       45: getstatic   #16     // Field java/lang/System.out:Ljava/io/PrintStream;
       48: ldc         #24     // String false branch
       50: invokevirtual #27     // Method java/io/PrintStream.println:(Ljava/lang/
String;)V
       53: goto        64
       56: getstatic   #16     // Field java/lang/System.out:Ljava/io/PrintStream;
       59: ldc         #29     // String true branch
       61: invokevirtual #27     // Method java/io/PrintStream.println:(Ljava/lang/
String;)V
       64: return
}
```

Listing 7.12: Konsolen-Ausgabe der Felder

```
15
0
```

7.5 If-Verzweigungen

Listing 7.13: If-Verzweigungen

```
function main(args: string[]) {
    var value = if (3 > 4) 5 else 6
    print(value)

    if(3 < 4) {
        print("true branch")
    } else {
        print("false branch")
    }
}
```

Listing 7.14: Bytecode der If-Verzweigungen

```
public class Main {
    public static void main(java.lang.String[]);
    Code:
        0: ldc         #7      // int 3
        2: ldc         #8      // int 4
        4: if_icmpgt   11
        7: iconst_0
        8: goto        12
       11: iconst_1
       12: ifne        20
       15: ldc         #9      // int 6
       17: goto        22
       20: ldc         #10     // int 5
       22: istore_1
       23: getstatic   #16     // Field java/lang/System.out:Ljava/io/PrintStream;
       26: iload_1
       27: invokevirtual #22    // Method java/io/PrintStream.println:(I)V
       30: ldc         #7      // int 3
       32: ldc         #8      // int 4
       34: if_icmplt   41
       37: iconst_0
       38: goto        42
       41: iconst_1
       42: ifne        56
       45: getstatic   #16     // Field java/lang/System.out:Ljava/io/PrintStream;
       48: ldc         #24     // String false branch
       50: invokevirtual #27    // Method java/io/PrintStream.println:(Ljava/lang/
String;)V
       53: goto        64
       56: getstatic   #16     // Field java/lang/System.out:Ljava/io/PrintStream;
       59: ldc         #29     // String true branch
       61: invokevirtual #27    // Method java/io/PrintStream.println:(Ljava/lang/
String;)V
       64: return
}
```

Listing 7.15: Konsolen-Ausgabe der If-Verzweigungen

```
6
true branch
```

7.6 For-Schleifen

Listing 7.16: For-Schleifen

```
function main(args: string[]) {
    var n = 200

    for (var i = 0; i <= n; i = i+10) {
        print(i)
    }
}
```

Listing 7.17: Bytecode der For-Schleife

```
public class Main {
    public static void main(java.lang.String[]);
    Code:
        0: ldc          #7      // int 200
        2: istore_1
        3: ldc          #8      // int 0
        5: istore_2
        6: iload_2
        7: iload_1
        8: if_icmple    15
        11: iconst_0
        12: goto         16
        15: iconst_1
        16: ifeq         34
        19: getstatic    #14     // Field java/lang/System.out:Ljava/io/PrintStream;
        22: iload_2
        23: invokevirtual #20     // Method java/io/PrintStream.println:(I)V
        26: iload_2
        27: ldc          #21     // int 10
        29: iadd
        30: istore_2
        31: goto         6
        34: return
}
```

Listing 7.18: Konsolen-Ausgabe der For-Schleife

```
0
10
i is 20:
20
30
40
50
60
70
80
90
```

```
100
110
120
130
140
150
160
170
180
190
200
```

7.7 Umfangreicheres Beispiel

Die Tests bisher beschränkten sich auf einzelne Eigenschaften von *toya*. Um aber auch das Zwischenspiel von mehreren Eigenschaften zu testen, wird nun noch ein umfangreicheres Programm analysiert. Dieses Programm ruft eine Funktion auf, welche Zeichenketten auf der Konsole ausgibt, definiert Variablen von Felder und primitiven Datentypen, iteriert über eine For-Schleife, welche eine If-Verzweigung enthält und verändert und liest Felder.

Listing 7.19: Quelltext des umfangreicheren Beispiels

```
function printIntro(n: int) {
    print("Welcome to a simple toya program")
    print("Calculating numbers up to: ")
    print(n)
    print("-----")
}

function main(args: string[]) {
    var n = 200
    printIntro(n)

    for (var i = 0; i <= n; i = i+10) {
        if (i == 20) {
            print("i is 20:")
        }
        print(i)
    }

    var boolArr = new boolean[2]
    boolArr[1] = true
    print(boolArr[0])
    print(boolArr[1])
}
```

Da das Anzeigen des Bytecodes bei diesem umfangreicheren Beispiel zu lange ist und alle Fragmente in den anderen Tests bereits zu sehen sind, wird der Bytecode an dieser Stelle ausgelassen.

Listing 7.20: Konsolen-Ausgabe des umfangreicheren Beispiels

```
Welcome to a simple toya program
Calculating numbers up to:
200
```

```
-----  
0  
10  
i is 20:  
20  
30  
40  
50  
60  
70  
80  
90  
100  
110  
120  
130  
140  
150  
160  
170  
180  
190  
200  
false  
true
```


Kapitel 8

Zusammenfassung, Schlüsse und Lehren

Anhang A

Technische Informationen

Anhang B

Ergänzende Inhalte

Auflistung der ergänzenden Materialien zu dieser Arbeit, die zur digitalen Archivierung an der Hochschule eingereicht wurden (als ZIP-Datei).

B.1 PDF-Dateien

Pfad: /

thesis.pdf Finale Master-/Bachelorarbeit (Gesamtdokument)

B.2 Mediendaten

Pfad: /media

*.ai, *.pdf Adobe Illustrator-Dateien

*.jpg, *.png Rasterbilder

*.mp3 Audio-Dateien

*.mp4 Video-Dateien

B.3 Online-Quellen (PDF-Kopien)

Pfad: /online-sources

Reliquienschrein-Wikipedia.pdf

Anhang C

Fragebogen

Anhang D

LaTeX-Quellcode

Quellenverzeichnis

Online-Quellen

- [1] *Reliquienschrein*. 20. Okt. 2020. URL: <https://de.wikipedia.org/wiki/Reliquienschrein> (besucht am 12.05.2021).

Messbox zur Druckkontrolle

— Druckgröße kontrollieren! —



— Diese Seite nach dem Druck entfernen! —